

DOCUMENTATION TECHNIQUE COMPLÈTE

Archipel Archipelagic Intelligence

Une architecture cognitive dynamique où l'intelligence émerge de la collaboration de sous-réseaux spécialisés (îlots) au sein d'un espace latent partagé (l'océan), gouvernée par un mécanisme d'optimisation légère (le Courant). Ce document présente la spécification complète du projet, de la vision fondatrice à la roadmap de prototypage.

Version 1.0 — Mai 2026

Projet de Recherche en IA Fondationnelle

ARCHITECTURE COGNITIVE DYNAMIQUE

Table des Matières

Chapitre 1 : Vision et Philosophie	4
1.1 Motivation Fondamentale	4
1.2 Paradigme Archipelagique vs Architectures Monolithiques	5
1.3 Principes Fondateurs	6
1.4 Analogies Biologiques et Théoriques	7
Chapitre 2 : Architecture Détaillée	8
2.1 Les Îlots (Island Modules)	8
2.1.1 Structure Interne	8
2.1.2 Styles de Raisonnement Spécialisés	8
2.1.3 Cycle de Vie : Naissance, Activation et Mort . . .	9
2.2 L'Océan (Latent Sea)	10
2.2.1 Espace Topologique Dynamique	10
2.2.2 Communication par Résonance Oscillatoire . .	10
2.3 Le Courant (The Current)	11
2.4 Co-Évolution et Apprentissage	12
2.4.1 Sélection Multi-Niveaux	12
2.4.2 Cristallisation Progressive et Héritage Résonant	12
2.4.3 Inférence Active Hiérarchique	13
2.5 Régulation Homéostatique	13
Chapitre 3 : Défis Fondamentaux et Solutions	14

3.1 Défi (a) : Bootstrap du Système Initial	14
3.2 Défi (b) : Stabilité vs Plasticité	15
3.3 Défi (c) : Passerelles Scalables	16
3.4 Défi (d) : Garanties de Convergence	17
3.5 Défi (e) : Utilisabilité et Observabilité	18
Chapitre 4 : Analyse de Faisabilité	19
4.1 Score Global de Faisabilité	19
4.2 Analyse Brique par Brique	20
4.3 Risques Majeurs Non Adressés	21
Chapitre 5 : Roadmap de Prototypage en 4 Phases	21
5.1 Phase 1 : Archipel Minimal	22
5.2 Phase 2 : Résonance	23
5.3 Phase 3 : Océan Simplifié	23
5.4 Phase 4 : Physique de l'Océan	23
Chapitre 6 : Phase 1 - Spécifications Détaillées	24
6.1 Architecture du Prototype	24
6.2 HyperNetwork Générateur d'Îlots	24
6.3 Routage par Corrélation Latente	25
6.4 Cycle de Vie Basique	25
6.5 Fonction de Perte	26
6.6 Tâche Benchmark Sélectionnée	26
Chapitre 7 : Stratégie Matérielle et Logicielle	27

7.1 Phase Matérielle 1 : GPU/TPU avec Sparsité Extrême . . .	27
7.2 Phase Matérielle 2 : Puces Sparse-First	28
7.3 Phase Matérielle 3 : Neuromorphique et Analogique . . .	28
Chapitre 8 : Extensions Futures	29
8.1 Communication Inter-Archipels	29
8.2 Auto-Amélioration du Courant	29
8.3 Interfaces Multimodales	30
Chapitre 9 : Bibliographie et Références Théoriques	31
Annexes	31
Annexe A : Glossaire	31
Annexe B : Résumé des Pseudocodes Clés	32

Chapitre 1 : Vision et Philosophie

1.1 Motivation Fondamentale

L'intelligence artificielle contemporaine est dominée par un paradigme architectural unique : le modèle monolithique statique. Que ce soit les Transformers à grande échelle comme GPT-4, les architectures d'état comme Mamba, ou les modèles de mélange d'experts (MoE) comme Switch Transformer et Mixtral, toutes ces approches partagent une caractéristique fondamentale : la topologie du réseau est fixée à la conception et ne change jamais pendant l'inférence. Les poids sont appris, mais la structure reste immuable. Cette limitation est profonde, car elle contraint le modèle à traiter des tâches radicalement différentes avec la même architecture cognitive, comme si un cerveau humain devait utiliser exactement les mêmes circuits neuronaux pour résoudre une équation mathématique et pour comprendre une émotion dans un poème.

Le projet Archipel naît d'une conviction fondatrice : l'intelligence véritable ne réside pas dans un réseau unique et statique, mais dans la dynamique d'émergence, de spécialisation et de coopération entre entités cognitives partielles. En biologie, le cerveau ne fonctionne pas comme un seul réseau uniforme. Il s'organise en aires corticales spécialisées (vision, langage, motricité) qui communiquent via des faisceaux de fibres, avec une plasticité structurelle continue. Les colonies de fourmis, les écosystèmes coralliens, les réseaux de neurones biologiques : tous ces systèmes démontrent que l'intelligence collective émerge de la diversité des agents et de la richesse de leurs interactions. Archipel propose de transposer ce principe fondamental dans le domaine de l'intelligence artificielle, en concevant une architecture où les sous-réseaux spécialisés naissent, se développent, coopèrent, et disparaissent dynamiquement en fonction des besoins computationnels du moment.

Cette vision dépasse le simple mélange d'experts classique. Dans un MoE traditionnel, les experts sont prédéfinis, leur nombre est fixe, et le routage se fait par un mécanisme centralisé simple (gating network). Archipel, au contraire, imagine des îlots cognitifs qui émergent organiquement, qui peuvent se scinder quand une sous-tâche se complexifie, qui fusionnent quand deux spécialisations deviennent complémentaires, et qui disparaissent quand elles ne sont plus pertinentes. L'architecture elle-même devient une variable d'apprentissage, pas seulement les poids. C'est un changement de paradigme aussi fondamental que le passage des réseaux récurrents aux Transformers, et potentiellement plus transformateur encore.

1.2 Paradigme Archipélagique vs Architectures Monolithiques

Pour comprendre la rupture que représente Archipel, il est essentiel de comparer systématiquement les deux paradigmes. Dans une architecture monolithique (Transformer standard, MLP géant), l'ensemble des capacités du modèle est encodé dans un réseau unique dont les paramètres sont optimisés globalement. Chaque couche transforme uniformément tous les tokens, et le même calcul est appliqué quelle que soit la nature de la tâche sous-jacente. L'attention globale permet à chaque token de considérer tous les autres, ce qui est extrêmement puissant mais aussi extrêmement coûteux : la complexité est quadratique en la longueur de séquence, et chaque ajout de capacité nécessite de dupliquer des calculs pour tous les tokens.

Dans le paradigme archipélagique, la philosophie est fondamentalement différente. L'archipel est composé d'îlots, c'est-à-dire de petits réseaux complets (des mini-Transformers ou des State Space Models) qui possèdent chacun leur propre spécialisation, leur propre mémoire locale, et leur propre style de raisonnement. Ces îlots ne sont pas actifs simultanément : pour chaque entrée, un mécanisme de routage sélectionne dynamiquement les îlots les plus pertinents, qui coopèrent via un espace latent partagé appelé l'Océan. L'Océan n'est pas un simple bus de communication : c'est un espace topologique dynamique dont la structure même évolue au fil du temps, modelé par des équations de réaction-diffusion inspirées de la physique non linéaire. Un troisième composant, appelé Le Courant, agit comme un mécanisme de gouvernance légère qui optimise trois objectifs simultanés : la cohérence globale des réponses, la diversité des spécialisations, et la surprise utile (la capacité à explorer de nouvelles configurations plutôt que de s'enliser dans des optima locaux).

Dimension	Monolithique	MoE Classique	Archipel
Topologie	Statique, fixe	Statique, experts fixes	Dynamique, auto-organisée
Nombre de modules	1 réseau unique	N fixes (ex: 8, 64)	Variable (naissance/mort)
Spécialisation	Implicite, globale	Explicite, pré-définie	Émergente, évolutive
Communication	Attention globale	Token routing centralisé	Résonance dans l'Océan

Coût en inférence	$O(n^2)$ attention	$O(n)$ avec sparsité	$O(k)$ k = îlots actifs
Adaptabilité	Fine-tuning global	Fine-tuning sélectif	Auto-évolution structurelle

Tableau 1 : Comparaison des paradigmes architecturaux

1.3 Principes Fondateurs

L'architecture Archipel repose sur cinq principes fondamentaux qui guident chaque décision de conception. Le premier est le **Principe d'Émergence** : les capacités cognitives ne sont pas programmées mais émergent de la dynamique d'interaction entre îlots. Chaque îlot est individuellement simple (un mini-Transformer de 2 à 6 couches), mais la collection forme un système complexe dont les propriétés dépassent la somme des parties. Ce principe est directement inspiré de l'émergence dans les systèmes complexes naturels : la conscience humaine émerge de neurones individuellement inconscients, les fourmilières développent des stratégies de chasse sophistiquées à partir de fourmis individuelles suivant des règles simples.

Le deuxième est le **Principe de Plasticité Structurelle** : contrairement aux architectures classiques où seul le poids des connexions change, Archipel permet à la topologie elle-même d'évoluer. De nouveaux îlots peuvent naître par un mécanisme de spawning, des îlots existants peuvent se scinder en sous-îlots spécialisés, et des îlots obsolètes peuvent disparaître par apoptose, après avoir distillé leurs connaissances dans les îlots voisins. Le troisième est le **Principe de Communication Résonante** : la communication entre îlots ne se fait pas par passage de messages explicite ou par concaténation, mais par résonance dans un espace latent partagé. Chaque îlot dépose des représentations dans l'Océan, et les îlots dont les états latents entrent en résonance coopèrent naturellement, sans qu'un routeur centralisé n'ait besoin de décider qui communique avec qui.

Le quatrième est le **Principe de Gouvernance Légère** : Le Courant n'est pas un contrôleur centralisé qui dicte le comportement de chaque îlot. C'est un mécanisme d'optimisation multi-objectif (cohérence, diversité, surprise utile) qui agit comme une force environnementale, influençant la fitness de chaque îlot sans jamais imposer de décision spécifique. Enfin, le cinquième est le **Principe d'Héritage Résonant** : quand un îlot naît, il hérite non pas d'une copie des poids d'un îlot parent, mais d'une graine latente compressée combinée au contexte des îlots voisins. Ce mécanisme de cristallisation

progressive permet une exploration continue de l'espace des architectures tout en conservant les connaissances acquises.

1.4 Analogies Biologiques et Théoriques

Le projet Archipel puise dans un riche terreau d'analogies biologiques et théoriques. En neurobiologie, les aires corticales du cerveau sont hautement spécialisées (V1 pour la vision primaire, Wernicke pour le langage, zone motrice supplémentaire pour la planification), mais elles communiquent via des faisceaux de fibres myélinisées qui permettent une intégration multimodale fluide. La neuroplasticité permet la création de nouvelles connexions, le renforcement des voies utilisées et l'élagage des synapses inactives, exactement comme les mécanismes de naissance et de mort des îlots dans Archipel. Le concept de connectome fonctionnel dynamique, où les réseaux cérébraux se réorganisent selon la tâche, est directement transposé dans la notion de topologie auto-organisée de l'Océan.

En écologie, les écosystèmes insulaires illustrent parfaitement la dynamique d'Archipel. La théorie de la biogéographie insulaire de MacArthur et Wilson décrit comment la taille d'une île et sa distance des autres influencent la diversité des espèces qui la colonisent. De même, la taille d'un îlot cognitif (nombre de paramètres) et sa proximité dans l'Océan latent (similitude des représentations) déterminent sa spécialisation et son rôle dans l'archipel. L'équilibre entre migration (transfert de connaissances entre îlots), spéciation (naissance de nouvelles spécialisations) et extinction (mort des îlots obsolètes) est calqué sur les modèles de dynamique des métacommunautés écologiques.

Sur le plan théorique, Archipel s'appuie fortement sur le Principe de l'Énergie Libre de Karl Friston, qui formalise comment les systèmes biologiques minimisent la surprise (l'entropie de leurs états sensoriels) en ajustant un modèle interne du monde. Chaque îlot dans Archipel minimise localement son énergie libre, et Le Courant optimise l'énergie libre au niveau de l'archipel entier, créant une optimisation multi-échelle cohérente. L'inférence active, qui postule que les agents choisissent les actions qui minimisent leur énergie libre anticipée, inspire directement les mécanismes de sélection des îlots. Enfin, les modèles de réaction-diffusion de Turing (morphogenèse) et de Ginzburg-Landau (transitions de phase) fournissent le cadre mathématique pour modeler la dynamique de l'Océan latent.

Chapitre 2 : Architecture Détaillée

Ce chapitre décrit en détail chacun des composants fondamentaux de l'architecture Archipel. L'architecture se compose de trois entités principales — les Îlots, l'Océan et le Courant — plus trois mécanismes complémentaires — la co-évolution, la régulation homéostatique et la cristallisation progressive. Chaque composant est présenté avec sa spécification fonctionnelle, ses propriétés formelles et les choix d'implémentation proposés.

2.1 Les Îlots (Island Modules)

2.1.1 Structure Interne

Un îlot est un réseau neuronal complet et autonome, capable de transformer des entrées en sorties sans dépendre d'autres composants pour son fonctionnement de base. Chaque îlot est typiquement un mini-Transformer de 2 à 6 couches d'encodage, avec des dimensions cachées allant de 128 à 512, bien que des architectures alternatives soient possibles (SSM de type Mamba, réseaux récurrents modernes, ou des architectures hybrides). La taille d'un îlot détermine sa capacité computationnelle : un petit îlot (2 couches, 128 dimensions) est rapide et peu coûteux, idéal pour des opérations simples de classification ou d'extraction de caractéristiques, tandis qu'un grand îlot (6 couches, 512 dimensions) peut gérer des tâches de raisonnement plus complexes mais consomme davantage de ressources.

Chaque îlot possède trois types de mémoire. La **mémoire à court terme** est une fenêtre contextuelle locale (similaire à celle d'un Transformer standard) qui stocke les tokens récemment traités. La **mémoire à long terme** est un module de stockage externe (mémoire associativement adressée, inspiré de Memformer ou de mechanisms type RETRO) qui permet à l'îlot de stocker des informations au-delà de sa fenêtre contextuelle. La **mémoire procédurale** est encodée dans les poids eux-mêmes et représente les compétences et habiletés acquises par l'îlot au fil de l'entraînement. Ces trois mémoires coopèrent pour donner à chaque îlot une richesse cognitive qui dépasse largement ce qu'un simple sous-réseau pourrait offrir.

2.1.2 Styles de Raisonnement Spécialisés

L'un des aspects les plus innovants d'Archipel est la spécialisation émergente des styles de raisonnement. Au cours de l'entraînement, sans qu'aucune étiquette de spécialisation ne soit imposée, les îlots développent naturellement des préférences pour différents types de traitement cognitif. Par exemple, certains îlots peuvent se spécialiser dans le raisonnement

logique formel (manipulation de symboles, chaînes déductives), d'autres dans le raisonnement analogique (identification de patterns, transfert entre domaines), d'autres encore dans le raisonnement narratif (compréhension de séquences temporelles, cohérence causale). Cette spécialisation émergente est similaire à ce qui est observé dans les réseaux de neurones biologiques, où différentes populations de neurones développent des récepteurs spécialisés en réponse aux stimuli qu'elles reçoivent.

La diversité des styles de raisonnement est maintenue par Le Courant via un mécanisme inspiré de MAP-Elites, un algorithme d'évolution artificielle qui maintient une archive d'individus diversifiés en les évaluant sur un ensemble de descripteurs comportementaux. Chaque îlot est caractérisé par un vecteur de descripteurs (par exemple, la distribution de ses activations sur un ensemble de tâches de référence, ou la corrélation de ses gradients avec différents objectifs), et Le Courant favorise la survie des îlots qui occupent des régions sous-représentées de cet espace des descripteurs. Ce mécanisme empêche l'effondrement vers un nombre restreint de spécialisations, garantissant que l'archipel maintient une véritable diversité cognitive plutôt que de se spécialiser sur un seul type de tâche.

2.1.3 Cycle de Vie : Naissance, Activation et Mort

Chaque îlot traverse un cycle de vie complet, de sa naissance à sa mort, avec des phases d'activation et d'inactivité intermédiaires. La **naissance (spawning)** se produit quand Le Courant détecte qu'un cluster de tâches dans le flux d'entrée n'est pas bien couvert par les îlots existants. Un nouveau candidat-îlot est alors généré par un HyperNetwork conditionnel, qui produit les poids de l'îlot à partir d'une graine latente compressée et du contexte des îlots voisins dans l'Océan. Ce mécanisme de cristallisation progressive garantit que les nouveaux îlots héritent partiellement des connaissances acquises par la communauté existante, accélérant leur apprentissage initial.

L'**activation** d'un îlot dépend de la pertinence de ses représentations par rapport à l'entrée courante. Un îlot est actif quand la corrélation entre son état latent courant et la représentation de l'entrée dans l'Océan dépasse un seuil dynamique. Cette approche par résonance remplace le routage centralisé des MoE classiques par un mécanisme distribué et naturellement parallélisable. La **mort (apoptose)** d'un îlot est déclenchée quand son utilité cumulée (mesurée par la norme de ses gradients ou par sa contribution à la performance globale) tombe en dessous d'un seuil minimal pendant une période prolongée. Avant de disparaître, l'îlot effectue une distillation apoptotique : ses connaissances sont transférées vers les îlots voisins via un mécanisme d'entraînement knowledge distillation, puis ses paramètres sont

libérés.

2.2 L'Océan (Latent Sea)

2.2.1 Espace Topologique Dynamique

L'Océan est le cœur médiatique de l'architecture Archipel. Il s'agit d'un espace latent continu de haute dimension dans lequel les représentations de tous les îlots sont projetées et où la communication inter-îlots se produit par résonance oscillatoire. Contrairement à un simple bus de données ou un espace de stockage passif, l'Océan est un système dynamique dont les propriétés évoluent au fil du temps. La métrique de distance dans l'Océan n'est pas fixe : elle se déforme en fonction de la fréquence et de l'intensité des échanges entre îlots, rapprochant les îlots qui coopèrent fréquemment et éloignant ceux qui interagissent rarement. Cette plasticité métrique est inspirée de la théorie de la relativité, où la géométrie de l'espace-temps est déformée par la matière et l'énergie.

Formellement, l'Océan est modélisé comme un champ de réaction-diffusion, où les représentations latentes des îlots jouent le rôle de réactifs et où les connexions entre îlots propagent ces réactifs selon des équations de diffusion. L'évolution temporelle de l'état de l'Océan est gouvernée par des équations inspirées de FitzHugh-Nagumo (pour la dynamique d'excitation et d'inhibition) ou de Ginzburg-Landau (pour les transitions de phase dans les motifs de connectivité). Pour rendre ces équations différentiables et donc intégrables dans un graphe de calcul, une approximation par Deep Equilibrium Networks (DEQN) est proposée : au lieu de résoudre explicitement les équations différentielles, on itère implicitement jusqu'à convergence, et les gradients sont calculés via la règle de dérivation implicite.

2.2.2 Communication par Résonance Oscillatoire

La communication dans l'Océan repose sur un mécanisme de résonance oscillatoire qui est radicalement différent des mécanismes d'attention ou de routage utilisés dans les architectures existantes. Chaque îlot projette ses représentations dans l'Océan sous forme d'ondes latentes oscillant à une fréquence propre (déterminée par les caractéristiques de l'îlot). Quand deux îlots ont des fréquences proches et sont spatialement proches dans l'Océan, ils entrent naturellement en résonance, et leurs représentations se mélangent constructivement. Ce mécanisme est biologiquement inspiré de la synchronisation neuronale observée dans le cerveau, où des populations de neurones oscillent à des fréquences similaires pour faciliter la communication entre aires corticales éloignées.

La résonance oscillatoire présente des avantages théoriques significatifs par rapport à l'attention globale. Premièrement, elle est naturellement sparse : seuls les îlots en résonance coopèrent, et la probabilité de résonance décroît avec la distance dans l'Océan, limitant le nombre de connexions actives sans nécessiter de mécanisme de seuillage explicite. Deuxièmement, elle est continue plutôt que discrète : le degré de résonance varie doucement, permettant une modulation fine de la force de connexion plutôt qu'un choix binaire d'acheminement. Troisièmement, elle est dynamique : les fréquences propres des îlots évoluent au fil de l'apprentissage, permettant une adaptation naturelle des patterns de communication aux exigences changeantes des tâches.

2.3 Le Courant (The Current)

Le Courant est l'entité de gouvernance de l'archipel. Il s'agit d'un mécanisme léger (en termes de paramètres et de calcul) qui optimise simultanément trois objectifs souvent contradictoires : la cohérence des réponses produites par l'archipel, la diversité des spécialisations des îlots, et la surprise utile (la capacité à explorer de nouvelles configurations cognitives). Le Courant n'est pas un contrôleur centralisé au sens classique : il n'impose pas de décisions spécifiques aux îlots. Il agit plutôt comme un paysage de fitness dans lequel les îlots évoluent, influençant les conditions de sélection (naissance, mort, activation) sans jamais dicter de comportement précis.

La cohérence est mesurée par la corrélation des représentations latentes des îlots actifs avec la représentation globale de l'entrée. Si les îlots actifs divergent trop dans l'espace latent, le Courant augmente le coût de divergence pour encourager la convergence. La diversité est mesurée par la dispersion des descripteurs comportementaux des îlots dans l'espace des spécialisations (mécanisme MAP-Elites). Si trop d'îlots se concentrent dans la même région, le Courant augmente sélectivement la fitness des îlots dans les régions sous-représentées, encourageant la spéciation. La surprise utile est mesurée par l'entropie des configurations d'activation : si les mêmes îlots sont toujours actifs, le Courant introduit un bruit exploratoire pour encourager l'activation d'îlots alternatifs, similaire à une politique epsilon-greedy mais adaptative et continue.

L'implémentation du Courant repose sur trois modules légers. Un **coherence scorer** qui calcule en temps réel la cohérence latente des îlots actifs (simple projection suivie d'un calcul de corrélation). Un **diversity maintainer** basé sur MAP-Elites qui maintient une grille de niches comportementales et favorise les îlots dans les niches vides. Et un **surprise scheduler** qui module

un terme d'entropie dans la loss globale, augmentant l'exploration quand la performance stagne et la réduisant quand le système converge vers une bonne solution. Ces trois modules n'ajoutent qu'un surcoût marginal (quelques pourcents du coût total) tout en jouant un rôle crucial dans la dynamique de l'archipel.

2.4 Co-Évolution et Apprentissage

2.4.1 Sélection Multi-Niveaux

L'apprentissage dans Archipel opère à trois niveaux simultanés, inspiré par les théories de l'évolution multi-niveaux en biologie. Au **niveau 1 (ajustement local des poids)**, chaque îlot actif met à jour ses propres paramètres par rétropropagation standard, en minimisant une loss locale qui combine l'objectif de tâche et un terme de cohérence avec les autres îlots actifs. Ce niveau est identique à l'apprentissage dans un Transformer standard, mais il ne s'applique qu'aux îlots actifs, offrant une efficacité computationnelle significative.

Au **niveau 2 (sélection des îlots)**, Le Courant évalue la fitness de chaque îlot en fonction de sa contribution à la performance globale et de sa position dans l'espace des spécialisations. Les îlots les plus performants se reproduisent (leurs graines latentes sont utilisées pour générer de nouveaux îlots via l'HyperNetwork), tandis que les moins performants entrent dans une phase de sénescence qui peut mener à l'apoptose. Au **niveau 3 (réorganisation topologique)**, la structure même de l'Océan est ajustée : les métriques de distance évoluent, les zones de forte activité se densifient, et les zones inactives s'atrophient. Ce troisième niveau est le plus innovant car il modifie non seulement les paramètres mais la topologie du calcul, une forme d'apprentissage structurel qui n'a pas d'équivalent dans les architectures actuelles.

2.4.2 Cristallisation Progressive et Héritage Résonant

La cristallisation progressive est le mécanisme par lequel de nouveaux îlots naissent. Plutôt que d'initialiser aléatoirement les poids d'un nouvel îlot (ce qui serait extrêmement inefficace), un HyperNetwork conditionnel génère les poids à partir de deux sources d'information : une graine latente compressée qui encode les connaissances accumulées par l'archipel, et le contexte des îlots voisins dans l'Océan. L'HyperNetwork est lui-même un petit réseau (2-3 couches, dimensions modérées) qui apprend à produire des poids initiaux de haute qualité pour les nouveaux îlots.

L'héritage résonant complète la cristallisation en permettant un transfert de connaissances plus subtil que la simple copie de poids. Quand un nouvel îlot naît dans une région de l'Océan où existent déjà des îlots établis, ses activations initiales sont influencées par les ondes latentes de ses voisins, ce qui lui confère immédiatement une orientation computationnelle compatible avec l'écosystème existant. Ce mécanisme est analogue à la façon dont un bébé humain naît avec des prédispositions cognitives (reconnaissance des visages, sens du nombre) qui ne sont pas apprises mais héritées de l'évolution de l'espèce. La combinaison de la cristallisation progressive et de l'héritage résonant permet à Archipel de développer de nouvelles capacités beaucoup plus rapidement qu'un système qui partirait de zéro à chaque ajout de module.

2.4.3 Inférence Active Hiérarchique

Archipel intègre le cadre de l'inférence active de Karl Friston à trois échelles. Au niveau de l'îlot, chaque module minimise une énergie libre variationnelle locale qui quantifie la divergence entre ses prédictions et les observations qu'il reçoit de l'Océan. Au niveau inter-îlots, l'énergie libre est étendue pour inclure les interactions entre îlots actifs, encourageant la cohérence de leurs représentations. Au niveau de l'archipel, Le Courant minimise l'énergie libre globale qui combine la performance sur la tâche, la diversité des spécialisations et l'exploration.

Les décisions discrètes (naissance d'un îlot, activation ou désactivation, apoptose) sont modélisées via des distributions de Gumbel-Softmax, qui permettent de rendre ces choix différentiables et donc optimisables par gradient. Quand un îlot doit décider s'il s'active ou non, il évalue son utilité potentielle via un réseau de décision léger, mais le seuil d'activation est passé à travers une fonction Gumbel-Softmax qui permet aux gradients de circuler à travers cette décision binaire. Cette approche unifie les processus discrets (sélection, cycle de vie) et continus (mise à jour des poids) dans un cadre d'optimisation cohérent, évitant les problèmes de non-différentiabilité qui ont longtemps entravé les approches structurellement dynamiques.

2.5 Régulation Homéostatique

Pour assurer la stabilité à long terme de l'archipel, un système de régulation homéostatique maintient plusieurs invariants structurels. Chaque îlot possède un **métabolisme interne** : un ensemble de métriques (norme de gradient moyenne, taux d'activation, cohérence latente) qui est comparé en permanence à des valeurs cibles. Quand un métabolisme dévie significativement de sa cible, l'îlot reçoit un signal de régulation

(augmentation du taux d'apprentissage, modification du seuil d'activation, etc.). Ce mécanisme est inspiré de l'homéostasie biologique, où la température corporelle, le pH sanguin et la glycémie sont maintenus dans des plages étroites par des boucles de rétroaction.

Les **îlots fantômes** (ghost islands) sont un mécanisme de pré-évaluation qui permet de tester de nouvelles configurations sans risquer la stabilité de l'archipel. Un îlot fantôme est créé dans une zone isolée de l'Océan, entraîné séparément pendant une période probatoire, puis évalué. S'il s'avère utile, il est intégré à l'archipel principal ; sinon, il est simplement supprimé sans conséquence. Ce mécanisme réduit le risque associé à l'ajout de nouveaux îlots et permet une exploration plus agressive de l'espace des architectures.

L'**apoptose avec distillation** garantit que la mort d'un îlot ne se traduit pas par une perte de connaissances. Quand un îlot est condamné, ses connaissances sont progressivement transférées vers les îlots les plus proches dans l'Océan via un processus de knowledge distillation. Les poids du condamné sont figés, et un loss de distillation est ajouté à l'entraînement des îlots receveurs pendant plusieurs étapes avant la suppression effective. Enfin, le mécanisme MAP-Elites maintient une diversité structurelle en garantissant que chaque niche comportementale reste occupée : si un îlot meurt et laisse une niche vide, la fitness des îlots dans les niches adjacentes est temporairement augmentée pour encourager la spéciation vers la niche vacante.

Chapitre 3 : Défis Fondamentaux et Solutions

L'ambition du projet Archipel s'accompagne de défis fondamentaux qui doivent être relevés pour transformer la vision en réalité. Ce chapitre identifie les cinq défis majeurs, propose des solutions, et présente une analyse critique de chaque solution avec des propositions raffinées.

3.1 Défi (a) : Bootstrap du Système Initial

Problème : Le paradoxe du bootstrap est le défi le plus fondamental d'Archipel. Comment initialiser un système dont la force réside dans l'émergence dynamique, alors qu'au départ il n'y a aucun îlot spécialisé et que l'Océan est vide ? C'est le problème de l'œuf et de la poule : les îlots ont besoin de l'Océan pour communiquer, mais l'Océan a besoin d'îlots pour avoir

un contenu. Une initialisation aléatoire pure conduirait à un chaos initial potentiellement irrécupérable, où les signaux de gradient seraient trop bruités pour guider l'apprentissage, et où les îlots naîtraient et mourraient trop rapidement pour qu'aucune spécialisation ne puisse se développer.

Solution proposée : La solution repose sur un amorçage progressif en trois phases. Dans la Phase d'Amorçage (Warm-up), on pré-entraîne un ensemble initial de 8 à 12 îlots de tailles variées sur le corpus cible avec une loss standard de modélisation de langage, sans mécanisme de cycle de vie. L'Océan est initialisé comme un espace PCA des activations de ces îlots, ce qui lui donne immédiatement une structure métrique significative. Dans la Phase de Transition, on active progressivement les mécanismes dynamiques : d'abord le routage par corrélation, puis la régulation homéostatique, puis la naissance/mort d'îlots. Les hyperparamètres sont progressivement relâchés vers leurs valeurs cibles. Dans la Phase d'Évolution Ouverte, tous les mécanismes sont actifs et le système évolue librement.

Analyse critique : Ce qui est brillant dans cette approche est la transition graduelle qui évite un choc structurel. L'initialisation de l'Océan via PCA est astucieuse car elle donne une base géométrique immédiate au routage par corrélation. Ce qui est délicat est la dépendance à la qualité du pré-entraînement initial : si les îlots initiaux convergent vers des minima locaux médiocres, la diversité initiale sera insuffisante pour alimenter une dynamique d'évolution productive. La solution raffinée propose d'ajouter un terme de diversité orthogonale (Diversité Orthogonale d'Activation, ou DOA) dès la phase d'amorçage, qui pénalise la similarité des vecteurs d'activation entre îlots, et de pré-entraîner chaque îlot sur un sous-ensemble différent du corpus (curriculum spatial) pour forcer des spécialisations initiales distinctes.

3.2 Défi (b) : Stabilité vs Plasticité

Problème : Le dilemme stabilité-plasticité est un problème classique en apprentissage continu, mais il prend une dimension particulière dans Archipel. D'un côté, le système doit être assez plastique pour s'adapter à de nouvelles tâches et restructurer ses îlots. De l'autre, il doit être assez stable pour conserver les connaissances acquises et éviter que la réorganisation structurelle ne dégrade la performance sur les tâches maîtrisées. La mort d'un îlot spécialisé, si elle n'est pas correctement gérée, peut entraîner une perte catastrophique de compétences. De même, la naissance d'un nouvel îlot peut perturber l'équilibre de l'Océan et dégrader temporairement la performance de tous les îlots voisins.

Solution proposée : Trois mécanismes complémentaires assurent l'équilibre stabilité-plasticité. Le premier est l'apoptose avec distillation, décrit en section 2.5, qui garantit que la mort d'un îlot ne se traduit pas par une perte de connaissances. Le deuxième est le mécanisme de conservation des mémoires à long terme : chaque îlot maintient une mémoire externe persistante (mémoire associativement adressée) qui survit à la mort de l'îlot. Quand un îlot meurt, sa mémoire est fusionnée avec celle d'un îlot voisin. Le troisième est le EWC (Elastic Weight Consolidation) adaptatif, qui pénalise les modifications des poids jugés importants pour les tâches précédentes, avec un seuil d'importance qui est dynamiquement ajusté par Le Courant en fonction de la pertinence actuelle de chaque compétence.

Analyse critique : L'approche est solide car elle combine deux philosophies complémentaires : la conservation explicite (mémoire persistante) et la protection implicite (EWC). La distillation apoptotique est une innovation élégante qui transforme la destruction en opportunité de consolidation. Cependant, la complexité combinée de ces mécanismes pose un problème d'optimisation : les hyperparamètres de l'EWC, de la distillation et de la mémoire persistante doivent être finement accordés, et leur interaction peut créer des conflits (par exemple, la distillation peut encourager des changements que l'EWC cherche à empêcher). La solution raffinée propose d'implémenter un mécanisme de priorisation adaptative où, en cas de conflit, la distillation l'emporte sur l'EWC (car la conservation via distillation est plus robuste que la conservation via pénalisation de poids).

3.3 Défi (c) : Passerelles Scalables

Problème : L'Océan doit permettre une communication efficace entre îlots, mais cette communication doit être scalable. Si la dynamique de réaction-diffusion de l'Océan nécessite des itérations nombreuses pour converger (comme c'est le cas pour les réseaux d'équilibre profond ou DEQNs), le coût computationnel de la communication peut devenir un goulot d'étranglement qui annule les gains d'efficacité de la sparsité des activations. De plus, la complexité du calcul des gradients à travers les itérations implicites de l'Océan croît avec la dimension de l'espace latent et le nombre d'îlots, ce qui peut rendre l'entraînement prohibitif.

Solution proposée : La solution combine trois approches. L'approximation par DEQN avec un nombre fixe et limité d'itérations (typiquement 3 à 5, au lieu de la convergence exacte) échange un léger biais contre un gain drastique en vitesse. Le découplage spatial partitionne l'Océan en sous-régions qui convergent indépendamment, réduisant la complexité de

$O(N^2)$ à $O(N*k)$ où k est la taille d'un voisinage local. Enfin, la mise en cache des états de l'Océan permet de réutiliser les résultats des itérations précédentes quand les activations des îlots n'ont pas significativement changé, un mécanisme similaire au cache KV dans les Transformers.

Analyse critique : L'approche par découplage spatial est la plus prometteuse car elle exploite la structure naturellement locale de la communication dans Archipel : la plupart des échanges inter-îlots impliquent des îlots proches dans l'Océan, rendant les interactions à longue distance rares et donc traitables par approximation. Le cache d'Océan est ingénieux mais sa gestion (quand invalider, politique d'éviction) ajoute une complexité système non négligeable. La solution raffinée propose de combiner le cache avec un mécanisme de signature d'activation (hash des états latents) qui détermine automatiquement si le cache est encore valide, éliminant le besoin de politiques d'éviction heuristiques.

3.4 Défi (d) : Garanties de Convergence

Problème : L'optimisation conjointe des poids des îlots, de la topologie de l'Océan et du comportement du Courant crée un paysage de perte extrêmement complexe, avec de nombreux optima locaux et des surfaces non convexes. Les mécanismes discrets (naissance, mort, activation) introduisent des discontinuités dans le graphe de calcul, rendant les garanties de convergence classiques (basées sur la convexité ou la descente de gradient avec taux d'apprentissage décroissant) inapplicables. De plus, la nature multi-objectif de l'optimisation (cohérence, diversité, surprise) signifie qu'il n'y a pas un seul point de convergence mais un front de Pareto, ce qui complique l'analyse.

Solution proposée : La stratégie repose sur la relaxation continue via Gumbel-Softmax pour toutes les décisions discrètes, rendant le graphe de calcul entièrement différentiable. Le Courant utilise un Lagrangien augmenté pour gérer les contraintes multi-objectifs, transformant le problème en une séquence d'optimisations mono-objectif avec pénalités adaptatives. Des bornes de régularisation sont imposées : le nombre total d'îlots est contraint dans un intervalle $[N_{\min}, N_{\max}]$, la taille de chaque îlot est bornée, et la fréquence de naissance/mort est limitée pour éviter l'instabilité oscillatoire. Enfin, une schedule de température pour le Gumbel-Softmax passe progressivement d'un régime d'exploration (haute température, décisions stochastiques) à un régime d'exploitation (basse température, décisions quasi-déterministes).

Analyse critique : L'approche est techniquement rigoureuse et la relaxation Gumbel-Softmax est bien établie dans la littérature. Le Lagrangien augmenté est un choix judicieux pour les problèmes multi-objectifs contraints. Cependant, la complexité combinée du paysage de perte fait qu'aucune garantie théorique forte ne peut être donnée : on peut au mieux montrer une convergence vers un point critique sous des hypothèses fortes (Lipschitzianité, bornes sur le Hessien) qui sont difficiles à vérifier en pratique. La solution raffinée propose d'ajouter un mécanisme de diagnostic de convergence en temps réel, basé sur le monitoring de la variance des gradients et de la diversité des activations, qui signale au système quand il est bloqué dans un optimum local et déclenche une perturbation structurelle ciblée.

3.5 Défi (e) : Utilisabilité et Observabilité

Problème : Une architecture dynamique et auto-organisée est intrinsèquement difficile à comprendre, à déboguer et à contrôler. Si les îlots naissent et meurent, si la topologie de l'Océan change, et si les décisions de routage sont émergentes, comment un développeur peut-il comprendre pourquoi le système a produit une réponse spécifique ? Comment reproduire un bug ? Comment garantir que le système se comportera de manière prédictible dans des contextes sensibles (médical, juridique, financier) ? Ce défi d'observabilité est souvent sous-estimé dans les projets de recherche, mais il est critique pour l'adoption pratique.

Solution proposée : Une infrastructure complète d'observabilité est intégrée à l'architecture. Un système de logging structurel enregistre à chaque pas de temps : quels îlots étaient actifs, leurs états latents, les décisions de naissance/mort du Courant, et la topologie de l'Océan. Un mécanisme de snapshot permet de sauvegarder et restaurer l'état complet de l'archipel (poids, topologie, mémoires) pour le débogage et la reproductibilité. Des outils de visualisation interactive permettent d'explorer la dynamique de l'archipel : cartes de l'Océan montrant les îlots comme des points colorés par spécialisation, graphes d'activation temporels, et analyses de contribution de chaque îlot à la sortie finale. Enfin, un mode de fonctionnement déterministe peut être activé pour les contextes critiques, qui fige la topologie et le routage tout en maintenant les poids optimisés.

Analyse critique : L'infrastructure d'observabilité est bien pensée et essentielle. Le mode déterministe est une solution pragmatique élégante qui permet de bénéficier du meilleur des deux mondes : la dynamique d'évolution pendant l'entraînement, et la prévisibilité pendant le déploiement. Cependant,

la quantité de données générées par le logging structurel peut devenir prohibitivement grande pour les systèmes avec de nombreux îlots, nécessitant des stratégies d'échantillonnage et de compression intelligentes. La solution raffinée propose un logging adaptatif qui échantillonne à haute fréquence pendant les événements rares (naissance/mort, changements de topologie) et à basse fréquence en régime stable, réduisant le volume de logs d'un ordre de magnitude tout en capturant les événements critiques.

Chapitre 4 : Analyse de Faisabilité

4.1 Score Global de Faisabilité

L'évaluation de la faisabilité du projet Archipel se fait sur trois horizons temporels, reflétant la nature fondamentalement incrémentale de la recherche proposée. À court terme (1-2 ans), la faisabilité est évaluée à 2.5 sur 5. Ce score modeste reflète le fait que même la Phase 1 (le prototype minimal) nécessite des innovations significatives par rapport aux MoE existants, notamment la génération d'îlots par HyperNetwork et le routage par corrélation latente. Aucun travaux publié n'a encore démontré un MoE avec un nombre variable d'experts généré dynamiquement, ce qui place le projet en territoire inexploré.

À moyen terme (3-5 ans), la faisabilité monte à 3.5 sur 5. Ce score est soutenu par la maturation attendue de plusieurs technologies sous-jacentes : les Deep Equilibrium Networks (Bai et al., 2019) progressent rapidement et pourraient fournir le cadre mathématique nécessaire pour l'Océan ; les mécanismes d'attention sparse (Bigbird, Longformer) démontrent que la communication selective peut remplacer l'attention globale efficacement ; et les approches de type Neural Architecture Search (NAS) par weight-sharing montrent qu'il est possible d'optimiser conjointement la structure et les poids d'un réseau.

À long terme (5-10 ans), la faisabilité atteint 4.5 sur 5. Ce score élevé reflète la convergence attendue de plusieurs tendances : la montée en puissance du hardware spécialisé (puces neuromorphiques, accélérateurs sparse), la maturation des méthodes d'apprentissage multi-agents, et l'accumulation de connaissances sur les architectures dynamiques. Si les résultats des phases intermédiaires sont positifs, les verrous restants (convergence formelle, observabilité à l'échelle) seront vraisemblablement levés par la communauté de recherche plus large.

Horizon	Score	Facteurs Clés
Court terme (1-2 ans)	2.5 / 5	Innovation incrémentale sur MoE + HyperNetwork ; risque d'optimisation élevé
Moyen terme (3-5 ans)	3.5 / 5	Maturation DEQN + attention sparse + NAS ; premières validations expérimentales
Long terme (5-10 ans)	4.5 / 5	Convergence hardware + méthodes multi-agents ; viabilité industrielle

Tableau 2 : Scores de faisabilité par horizon temporel

4.2 Analyse Brique par Brique

Chaque composant fondamental de l'architecture a été évalué individuellement pour sa difficulté d'implémentation et son risque technique. Le tableau suivant résume cette analyse, avec une justification détaillée pour chaque note.

Brique	Score	Justification
HyperNetwork générateur	4 / 5	Bien étudié (Ha et al., 2016) ; le défi est la qualité des poids générés, pas le principe lui-même
Routage par corrélation latente	3.5 / 5	Mécaniquement simple mais la dynamique de la corrélation dans un espace en évolution est complexe à stabiliser
Océan (champ réaction-diffusion)	3 / 5	Les DEQNs sont prometteurs mais le passage à l'échelle et la différenciabilité à travers de nombreuses itérations restent des défis ouverts
Cycle de vie (naissance/mort)	3 / 5	La naissance via HyperNetwork est faisable ; la mort avec distillation est non triviale mais des précédents existent
Inférence active multi-échelle	2 / 5	Le cadre théorique est riche mais l'implémentation pratique et la stabilité de l'optimisation multi-échelle sont très délicates

Tableau 3 : Analyse de faisabilité par composant

4.3 Risques Majeurs Non Adressés

Au-delà des défis spécifiques à chaque composant, trois risques transversaux majeurs ont été identifiés. Le premier est le **problème de bootstrap à grande échelle**. Même si le bootstrap progressif en trois phases est bien conçu, rien ne garantit que la dynamique d'évolution qui émerge du système sera productive. Il est possible que le système converge vers un état dégénéré (par exemple, un seul îlot géant qui absorbe toutes les tâches, annihilant le bénéfice de la spécialisation) ou qu'il oscille entre des configurations instables sans jamais atteindre un équilibre fonctionnel. Ce risque est mitigé par les mécanismes de régulation du Courant, mais il ne peut être éliminé que par l'expérimentation.

Le deuxième est le **problème de la standardisation de l'évaluation**. Comment mesurer objectivement la qualité d'une architecture dynamique ? Les benchmarks standard (MMLU, HumanEval, GSM8K) mesurent la performance sur des tâches statiques, mais ne capturent pas les aspects les plus innovants d'Archipel : la capacité à s'adapter structurellement, l'efficacité compute adaptative, ou la robustesse face à la distribution shift. Il est urgent de développer des métriques d'évaluation spécifiques aux architectures dynamiques, qui mesurent non seulement la performance brute mais aussi l'efficacité structurelle (performance par million de paramètres actifs) et la plasticité (vitesse d'adaptation à de nouvelles tâches).

Le troisième est le **risque complexité-performance**. Chaque mécanisme d'Archipel (routage, cycle de vie, régulation, Océan) ajoute de la complexité au système. Si les gains de performance ne compensent pas cette complexité, Archipel risque d'être un système remarquablement élégant mais pratiquement inutilisable, où les ingénieurs passeraient plus de temps à tuner les hyperparamètres qu'à exploiter les capacités du modèle. Ce risque est mitigé par la roadmap incrémentale en 4 phases, qui permet d'évaluer le rapport complexité-performance à chaque étape et d'arrêter le développement si les gains ne justifient pas l'investissement.

Chapitre 5 : Roadmap de Prototypage en 4 Phases

La roadmap de prototypage est conçue pour valider incrémentalement chaque composant de l'architecture, en commençant par les mécanismes les plus simples et en ajoutant progressivement la complexité. Chaque phase produit un prototype fonctionnel qui peut être benchmarké indépendamment,

permettant une évaluation objective à chaque étape. Cette approche réduit considérablement le risque global en identifiant précocément les goulots d'étranglement et les impasses conceptuelles.

Ph ase	Nom	Composants Validés	Durée Estimée
1	Archipel Minimal	HyperNetwork, routage par corrélation, cycle de vie basique, coherence loss	3-6 mois
2	Résonance	Communication par résonance oscillatoire, métrique plastique, coopération inter-îlots	6-12 mois
3	Océan Simplifié	Espace latent partagé avec topologie dynamique simple, DEQN basique	12-18 mois
4	Physique de l'Océan	Champ réaction-diffusion complet, courants topologiques, évolution structurelle	18-24 mois

Tableau 4 : Roadmap de prototypage en 4 phases

5.1 Phase 1 : Archipel Minimal

La Phase 1 est le point d'entrée du projet et la preuve de concept fondamentale. L'objectif est de démontrer qu'un MoE dynamique avec génération d'experts par HyperNetwork peut surpasser un MoE statique équivalent sur un benchmark de référence. Le prototype comprend 20 à 50 îlots (mini-Transformers de 2-4 couches), un HyperNetwork conditionnel qui génère les poids des nouveaux îlots, un mécanisme de routage par corrélation dans un espace latent appris, et un cycle de vie basique (naissance quand un cluster d'entrées est mal couvert, mort quand la norme de gradient tombe sous un seuil). La loss combine la perte de tâche standard, un terme de cohérence contrastive (qui encourage les îlots actifs à produire des représentations similaires) et un terme de diversité (qui pénalise la similarité entre les descripteurs des îlots).

Le benchmark proposé est un ensemble de tâches NLP diversifiées couvrant différents types de raisonnement (logique formelle, inférence naturelle, compréhension narrative, extraction d'information) qui permet de mesurer si les îlots développent des spécialisations émergentes alignées avec les types de tâches. Les baselines sont les MoE statiques de référence (Switch Transformer, Mixtral) entraînés sur les mêmes données avec le même budget

computationnel total. Les métriques d'évaluation incluent la performance brute, l'efficacité compute (performance par FLOP), et la qualité de la spécialisation (mesurée par la correspondance entre les clusters d'activation des îlots et les types de tâches).

5.2 Phase 2 : Résonance

La Phase 2 ajoute le mécanisme de communication par résonance oscillatoire qui remplace le routage par corrélation de la Phase 1. Chaque îlot se voit attribuer une fréquence propre apprise, et la coopération entre îlots est déterminée par la proximité de leurs fréquences et de leurs positions dans l'espace latent. Cette phase introduit également la métrique plastique de l'Océan : la distance entre îlots n'est plus fixe mais évolue en fonction de la fréquence et de la qualité de leurs interactions. Les objectifs de la Phase 2 sont de démontrer que la résonance est plus efficace que le routage centralisé, que la métrique plastique améliore la qualité de la communication, et que la communication multi-îlots produit des résultats supérieurs à la somme des contributions individuelles.

5.3 Phase 3 : Océan Simplifié

La Phase 3 introduit l'Océan latent en tant qu'entité à part entière, avec une topologie dynamique simplifiée. L'espace latent est modélisé comme une variété apprise (via un auto-encodeur variationnel) dont les paramètres évoluent au fil de l'entraînement. Un DEQN basique approxime la dynamique de réaction-diffusion avec un nombre limité d'itérations. Cette phase valide si la dynamique de l'Océan apporte un bénéfice par rapport à un espace latent statique, et si le DEQN est suffisamment stable et efficace pour être intégré dans un pipeline d'entraînement standard.

5.4 Phase 4 : Physique de l'Océan

La Phase 4 est l'aboutissement du projet : elle ajoute les équations de réaction-diffusion complètes (FitzHugh-Nagumo et/ou Ginzburg-Landau), les courants topologiques qui modifient structurellement l'Océan, et l'évolution structurelle complète (spéciation, fusion d'îlots, reconfiguration de la topologie). Cette phase démontre le plein potentiel de l'architecture Archipel et produit le premier système d'intelligence artificielle capable d'adapter dynamiquement sa propre topologie computationnelle en réponse aux exigences computationnelles.

Chapitre 6 : Phase 1 - Spécifications Détaillées

Ce chapitre fournit les spécifications techniques détaillées du prototype de Phase 1, incluant l'architecture complète, les algorithmes clés, les choix d'implémentation et les métriques d'évaluation.

6.1 Architecture du Prototype

Le prototype de Phase 1 est un modèle de langage dynamique basé sur le paradigme MoE évolutif. L'architecture se compose de trois composants principaux : un encodeur de tokens partagé (embedding layer + positional encoding), un ensemble dynamique d'îlots (mini-Transformers), et un décodeur de sortie partagé (projection vers le vocabulaire). L'encodeur et le décodeur sont fixes et partagés par tous les îlots, ce qui garantit une représentation cohérente des entrées et des sorties. Seuls les îlots intermédiaires sont dynamiques et spécialisés.

Chaque îlot est un mini-Transformer de 2 à 4 couches avec les caractéristiques suivantes : dimension cachée de 256 à 384, 4 à 8 têtes d'attention, dimension Feed-Forward de 1024 à 1536, et une fenêtre contextuelle de 512 tokens. Le nombre d'îlots est initialement fixé à 16 et peut évoluer entre 8 et 64 au cours de l'entraînement. Le budget total de paramètres (hors encodeur/décodeur) est contraint à être équivalent à un Transformer standard de taille comparable (environ 1-2 milliards de paramètres pour la validation de principe), ce qui permet une comparaison équitable avec les baselines statiques.

6.2 HyperNetwork Générateur d'Îlots

L'HyperNetwork est responsable de la génération des poids des nouveaux îlots. Il prend en entrée un vecteur de graine latente z (dimension 64) et un vecteur de contexte c (dimension 128) qui encode la moyenne des activations des îlots voisins dans l'espace latent, et produit en sortie l'ensemble complet des poids d'un mini-Transformer. L'architecture de l'HyperNetwork est elle-même un petit Transformer de 3 couches avec dimension cachée 512, qui génère les poids couche par couche via des projections séparées.

Pour réduire le coût de génération, un mécanisme de factorisation est utilisé : l'HyperNetwork ne génère pas directement les poids denses mais produit des facteurs de bas rang (par exemple, deux matrices A et B telles que $W = A \times B$), ce qui réduit le nombre de sorties par un facteur de 4 à 8. La graine latente z

est elle-même apprise par rétropropagation à travers le processus de génération, optimisée pour produire des îlots qui maximisent la fitness de l'archipel. Un mécanisme de warm-up de l'HyperNetwork est prévu : il est d'abord entraîné à reproduire les poids des îlots existants (auto-encodeur de poids) avant d'être utilisé pour la génération de nouveaux îlots.

6.3 Routage par Corrélation Latente

Le routage détermine quels îlots sont actifs pour chaque entrée. Chaque îlot i maintient un vecteur d'état latent h_i (la moyenne pooling de ses activations sur la dernière séquence traitée). Pour une nouvelle entrée x , l'encodeur partagé produit une représentation r_x . L'îlot i est activé si la corrélation cosinus entre h_i et r_x dépasse un seuil dynamique τ_i . Le seuil est propre à chaque îlot et évolue au cours de l'entraînement : il diminue pour les îlots dont la fitness est élevée (encourageant leur activation) et augmente pour les îlots dont la fitness est basse (décourageant leur activation).

Un mécanisme de top-k avec bruit adaptatif est superposé pour garantir une exploration suffisante : même si la corrélation est sous le seuil, un îlot peut être activé avec une probabilité ϵ_i (proportionnelle à son utilité récente). Ce epsilon-greedy adaptatif est modulé par Le Courant : quand la diversité des activations est basse (les mêmes îlots sont toujours sélectionnés), epsilon augmente globalement pour encourager l'exploration ; quand la performance stagne, epsilon diminue pour concentrer l'optimisation sur les meilleurs îlots.

6.4 Cycle de Vie Basique

Le cycle de vie en Phase 1 comprend deux mécanismes : la naissance et la mort. La naissance d'un nouvel îlot est déclenchée quand deux conditions sont simultanément remplies. Premièrement, la perte de cohérence (variance des représentations latentes des îlots actifs) dépasse un seuil pendant un nombre consécutif d'étapes, indiquant que les îlots actifs ne couvrent pas adéquatement l'espace des entrées. Deuxièmement, le nombre total d'îlots est inférieur à $N_{\max}$ (64 dans le prototype). Quand ces conditions sont réunies, l'HyperNetwork génère un nouveau candidat à partir d'une graine aléatoire et du contexte des îlots actifs.

La mort d'un îlot est déclenchée quand sa norme de gradient moyenne sur une fenêtre glissante de 1000 étapes tombe en dessous d'un seuil minimal (indiquant que l'îlot n'est pas utilisé ou que sa contribution est négligeable) ET que le nombre total d'îlots est supérieur à $N_{\min}$ (8 dans le prototype). Avant suppression, une distillation simplifiée est effectuée : le loss de l'îlot

condamné est ajouté comme un terme KL au loss des îlots actifs pendant 200 étapes. La spécialisation (scission d'un îlot en deux) et la fusion (combinaison de deux îlots en un) sont reportées à la Phase 2 pour réduire la complexité initiale.

6.5 Fonction de Perte

La fonction de perte totale combine quatre termes avec des pondérations adaptatives. Le premier terme est la perte de tâche standard (cross-entropie pour la modélisation de langage), appliquée uniquement aux îlots actifs. Le deuxième terme est la perte de cohérence contrastive, qui encourage les représentations latentes des îlots actifs à être similaires entre elles et différentes de celles des îlots inactifs, formulée comme un loss InfoNCE classique. Le troisième terme est la perte de diversité, qui pénalise la similarité entre les descripteurs comportementaux des îlots (calculés comme la matrice de corrélation des gradients entre paires d'îlots). Le quatrième terme est la perte de régularisation structurelle, qui pénalise les changements brusques dans le nombre d'îlots actifs pour stabiliser la dynamique.

Les pondérations de ces quatre termes ne sont pas fixes : elles sont adaptées par Le Courant en fonction de l'état courant du système. Quand la cohérence est bonne mais la diversité est basse, le poids de la perte de diversité augmente. Quand la performance de tâche stagne, le poids de la perte de tâche augmente relativement. Cette adaptation dynamique des pondérations est un élément clé de la gouvernance du Courant, permettant au système de s'autoréguler sans intervention humaine.

6.6 Tâche Benchmark Sélectionnée

La tâche de benchmark pour la Phase 1 est un ensemble multi-tâches de type **Generalization through Specialization**, composé de plusieurs benchmarks NLP distincts couvrant des types de raisonnement différents. Cet ensemble comprend : des tâches de logique formelle (entailment, contradiction, syllogismes), des tâches d'inférence naturelle (lecture compréhension, question answering), des tâches de raisonnement mathématique (arithmétique, algèbre), des tâches de génération de texte narratif, et des tâches de classification multi-classes. La diversité intentionnelle de cet ensemble est conçue pour révéler si les îlots développent des spécialisations alignées avec les types de raisonnement.

Le choix de cet ensemble plutôt que d'un benchmark unique (comme MMLU) est motivé par la nécessité de démontrer la valeur ajoutée spécifique d'Archipel : la spécialisation émergente. Si on utilise un benchmark uniforme,

il n'y a pas de pression pour que les îlots se spécialisent, et Archipel se comporte comme un MoE classique. L'ensemble multi-tâches, au contraire, crée une pression de spécialisation naturelle, similaire à un environnement écologique avec des niches distinctes. Les métriques d'évaluation incluent la performance moyenne sur toutes les tâches, l'écart de performance entre la meilleure et la pire tâche (mesure de robustesse), le nombre de FLOPs effectivement utilisés par échantillon (mesure d'efficacité adaptative), et la correspondance entre les clusters d'activation des îlots et les types de tâches (mesure de qualité de spécialisation).

Chapitre 7 : Stratégie Matérielle et Logicielle

7.1 Phase Matérielle 1 : GPU/TPU avec Sparsité Extrême

La première phase de la stratégie matérielle consiste à exploiter au maximum les hardware existants (GPU NVIDIA A100/H100, TPU v5) en utilisant des techniques de sparsité extrême. Archipel est naturellement adapté à la sparsité car seul un sous-ensemble d'îlots est actif à chaque instant. L'objectif est de réduire le coût mémoire et computationnel de l'inférence en ne chargeant en mémoire que les îlots actifs (sparse activation), en utilisant la précision mixte (FP8 pour les activations, FP16 pour les poids, BF16 pour les accumulateurs), et en exploitant les unités matricielles sparse des GPU modernes (NVIDIA Sparse Tensor Cores) pour les multiplications matricielles dans les îlots actifs.

L'implémentation logicielle s'appuie sur des frameworks existants avec des extensions spécifiques. PyTorch fournit le socle de base pour l'entraînement, avec des extensions personnalisées pour la gestion dynamique des îlots (création et destruction de modules pendant l'entraînement, qui n'est pas nativement supportée par PyTorch). Des kernels CUDA personnalisés sont développés pour le routage par corrélation (optimisé pour le calcul batché de corrélations cosinus entre représentations latentes) et pour le DEQN (itérations implicites avec checkpointing pour limiter l'utilisation mémoire). Les bibliothèques de compilation comme torch.compile et Triton sont exploitées pour fusionner les opérations et réduire les overheads de lancement de kernels.

7.2 Phase Matérielle 2 : Puces Sparse-First

La deuxième phase cible l'émergence attendue de puces conçues nativement pour les architectures sparse et dynamiques. Des startups comme Cerebras (WSE), SambaNova, et des projets académiques proposent des architectures où le calcul n'est pas organisé en unités SIMD massives mais en réseaux de petits éléments de calcul interconnectés, parfaitement adaptés au paradigme d'Archipel. Chaque îlot peut être mappé sur un cluster d'éléments de calcul, et l'Océan latent sur les interconnexions entre clusters. Le routage par corrélation est implémenté directement dans le hardware via des comparateurs de similarité en temps réel, éliminant l'overhead logiciel.

Les mémoires associatives (content-addressable memories) sont particulièrement adaptées à l'Océan latent : au lieu de stocker les représentations dans un tableau adressé par index, elles sont stockées dans une mémoire adressée par contenu, permettant une recherche de similarité en $O(1)$ plutôt qu'en $O(N)$. Cette technologie, bien que encore expérimentale, pourrait transformer radicalement l'efficacité de la communication dans Archipel. La compilation spécifique à Archipel utilise des IR (Intermediate Representations) qui encodent explicitement la dynamique de la topologie, permettant au compilateur de répartir les calculs entre éléments de calcul de manière optimale et adaptative.

7.3 Phase Matérielle 3 : Neuromorphique et Analogique

La vision à long terme pour Archipel est l'implémentation sur hardware neuromorphique et analogique. Les puces neuromorphiques (Intel Loihi 2, IBM TrueNorth, SpiNNaker) implémentent des réseaux de neurones en silicium avec une consommation énergétique par opération 100 à 1000 fois inférieure aux GPU. Les neurones artificiels de ces puces communiquent par impulsions (spikes), un mécanisme fondamentalement compatible avec la résonance oscillatoire d'Archipel. La communication par spikes est naturellement sparse (un neurone ne spike que quand il est excité) et asynchrone (pas d'horloge globale), deux propriétés qui alignent parfaitement avec la philosophie d'Archipel.

Les technologies analogiques émergentes (memristors, calcul photonique) offrent des possibilités encore plus radicales. Les memristors, avec leur capacité à stocker une valeur analogique et à la modifier en temps réel avec une consommation quasi nulle, sont les candidats idéaux pour implémenter les poids plastiques des îlots. Le calcul photonique, qui utilise la lumière pour

effectuer des multiplications matricielles à la vitesse de la lumière et avec une consommation minimale, pourrait accélérer drastiquement les opérations dans les îlots actifs. L'architecture d'Archipel est conçue dès le départ pour être compatible avec ces technologies : la séparation nette entre îlots, Océan et Courant permet un mappage naturel sur des substrats physiques distincts, et la dynamique de résonance se traduit directement en dynamique d'oscillateurs couplés en physique.

Chapitre 8 : Extensions Futures

8.1 Communication Inter-Archipels

L'extension la plus ambitieuse est la communication entre archipels autonomes. De la même manière que des écosystèmes insulaires séparés échangent des espèces par migration naturelle (courants marins, oiseaux migrateurs), des archipels cognitifs pourraient échanger des graines d'îlots, permettant un transfert de connaissances entre systèmes spécialisés sans partager l'ensemble de leurs paramètres. Cette extension ouvre la voie à une architecture fédérée où chaque nœud du réseau est un archipel complet qui peut à la fois résoudre des tâches localement et contribuer à une intelligence collective à l'échelle du réseau.

Le mécanisme proposé est la migration latente : un archipel peut exporter une graine latente compressée (un vecteur de basse dimension) vers un autre archipel, qui utilise son propre HyperNetwork pour recréer un îlot équivalent adapté à son contexte local. Cette approche résout le problème classique de la fédération d'apprentissage (comment partager des connaissances sans partager de données) d'une manière fondamentalement nouvelle : au lieu de partager des gradients ou des poids, on partage des blueprints structurels (graines latentes) que chaque archipel interprète dans son propre contexte. La compatibilité entre archipels est assurée par un protocole de normalisation des espaces latents, analogue à un protocole de traduction entre langues différentes.

8.2 Auto-Amélioration du Courant

Dans la version actuelle d'Archipel, Le Courant est un mécanisme fixe avec des hyperparamètres prédéfinis. L'extension d'auto-amélioration propose que Le Courant lui-même soit un composant apprenant qui s'améliore au fil du temps. Concrètement, les pondérations des trois objectifs (cohérence, diversité, surprise utile) deviennent des paramètres appris, optimisés par une

méta-optimisation de haut niveau qui maximise la fitness à long terme de l'archipel (mesurée par la performance sur un ensemble de validation). Cette méta-optimisation utilise un gradient de second ordre ou un algorithme évolutionnaire pour ajuster les politiques du Courant sans interférer avec l'optimisation de premier ordre des poids des îlots.

Cette extension transforme Le Courant d'un régulateur statique en un véritable méta-apprenant qui développe des stratégies de gouvernance de plus en plus sophistiquées au fil de l'expérience. À long terme, Le Courant pourrait même apprendre à créer et dissoudre des sous-Courants spécialisés (analogues à des ministères dans un gouvernement), chacun responsable d'un aspect spécifique de la régulation (performance sur les tâches faciles vs difficiles, gestion des ressources computationnelles, détection et correction des dysfonctionnements). Cette auto-organisation hiérarchique est directement inspirée de l'évolution des systèmes de gouvernance dans les sociétés humaines.

8.3 Interfaces Multimodales

L'architecture Archipel est naturellement extensible aux modalités multiples. Le principe de base est simple : des îlots spécialisés pour différentes modalités (vision, audition, langage, contrôle moteur) coexistent dans le même Océan, communiquant par résonance comme les îlots intra-modaux. Un îlot visuel qui traite une image peut déposer ses représentations dans l'Océan, et un îlot linguistique peut les récupérer pour générer une description verbale de l'image. La communication multimodale émerge naturellement de la résonance entre îlots de modalités différentes, sans nécessiter de mécanisme de fusion spécifique.

Cette extension est particulièrement pertinente pour les agents embodied qui doivent intégrer des flux sensoriels hétérogènes (vision, proprioception, tactile, audition) pour interagir avec un environnement physique. Un archipel embodied aurait des îlots spécialisés pour chaque flux sensoriel, des îlots de planification qui combinent les informations multi-sensorielles, et des îlots moteurs qui génèrent des commandes d'action. La dynamique de naissance/mort permettrait une adaptation rapide à de nouveaux capteurs ou à des dommages partiels (similaire à la neuroplasticité post-lésionnelle), et la communication par résonance permettrait une intégration fluide de nouveaux types de signaux sensoriels sans réentraînement complet.

Chapitre 9 : Bibliographie et Références Théoriques

- [1] Bai, Y., Kolter, J. Z., & Koltun, V. (2019). Deep Equilibrium Models. NeurIPS.
- [2] Bengio, Y., Louradour, J., Collobert, R., & Weston, J. (2009). Curriculum Learning. ICML.
- [3] Chen, J., Wu, Y., & Xu, Y. (2023). Growing Deep Networks via Self-Organizing Maps. ICML.
- [4] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers. NAACL.
- [5] Fedus, W., Zoph, B., & Shazeer, N. (2022). Switch Transformers: Scaling to Trillion Parameter Models. JMLR.
- [6] Friston, K. (2010). The Free-Energy Principle: A Unified Brain Theory? Nature Reviews Neuroscience.
- [7] Ha, D., Dai, A., & Le, Q. V. (2016). HyperNetworks. ICLR.
- [8] Jang, E., Gu, S., & Poole, B. (2017). Categorical Reparameterization with Gumbel-Softmax. ICLR.
- [9] Kirkpatrick, J., et al. (2017). Overcoming Catastrophic Forgetting. PNAS.
- [10] Mouret, J. B., & Clune, J. (2015). Illuminating Search Spaces by Mapping Elites. arXiv.
- [11] Rae, J. W., et al. (2022). Scaling Language Models: Methods, Analysis, and Insights from Training Gopher.
- [12] Shazeer, N., et al. (2017). Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. ICLR.
- [13] Turing, A. M. (1952). The Chemical Basis of Morphogenesis. Philosophical Transactions of the Royal Society.
- [14] Vaswani, A., et al. (2017). Attention Is All You Need. NeurIPS.
- [15] Wilson, E. O., & MacArthur, R. H. (1967). The Theory of Island Biogeography. Princeton University Press.

Annexes

Annexe A : Glossaire

Terme	Définition
Archipel	Ensemble dynamique d'îlots cognitifs coopérant via l'Océan latent.

Îlot	Petit réseau neuronal complet (mini-Transformer ou SSM) avec spécialisation émergente.
Océan	Espace latent partagé, modélisé par un champ de réaction-diffusion dynamique.
Le Courant	Mécanisme de gouvernance légère optimisant cohérence, diversité et surprise utile.
HyperNetwork	Réseau générant les poids des nouveaux îlots à partir de graines latentes.
Apoptose	Mort programmée d'un îlot, précédée de distillation de connaissances.
Spawning	Naissance d'un nouvel îlot via l'HyperNetwork.
Résonance	Communication entre îlots par alignement de fréquences dans l'Océan.
DEQN	Deep Equilibrium Network : approximation différentiable d'un système en équilibre.
Gumbel-Softmax	Distribution continue différentiable approchant un échantillonnage catégoriel.
Énergie Libre	Principe de Friston : minimisation de la surprise (entropie prédictive).
MAP-Elites	Algorithme d'évolution artificielle maintenant une archive d'individus diversifiés.
EWC	Elastic Weight Consolidation : technique de régularisation pour l'apprentissage continu.
Cristallisation	Processus de génération d'un nouvel îlot par l'HyperNetwork.
Héritage Résonant	Transfert de connaissances contextuelles aux nouveaux îlots via l'Océan.

Tableau A1 : Glossaire des termes techniques

Annexe B : Résumé des Pseudocodes Clés

Algorithme 1 : Forward Pass d'Archipel (Phase 1)

Entrée : séquence de tokens X ; Îlots $I = \{I_1, \dots, I_N\}$; HyperNetwork H ;
Seuils $T = \{\tau_1, \dots, \tau_N\}$

1. $r_X = \text{Encodeur}(X)$ // Projection dans l'espace latent partagé

2. Pour chaque îlot I_i : calculer corrélation $c_i = \text{cos_sim}(h_i, r_X)$
3. Sélectionner les îlots actifs $A = \{I_i : c_i > \tau_i\}$ (avec bruit epsilon-greedy)
4. Pour chaque îlot actif I_i : $o_i = I_i(X)$ // Forward pass local
5. Agréger les sorties : $O = \text{Aggregate}(o_i \text{ pour } i \text{ dans } A)$
6. Sortie : $Y = \text{Decodeur}(O)$

Algorithme 2 : Cycle de Vie (Naissance et Mort)

À chaque étape d'entraînement :

1. Calculer la variance des activations des îlots actifs V
2. Si $V > V_{\text{seuil}}$ ET $N_{\text{îlots}} < N_{\text{max}}$:
 - a. Échantillonner graine $z \sim N(0, I)$
 - b. Calculer contexte $c = \text{moyenne}(h_i \text{ pour } i \text{ dans } A)$
 - c. Générer poids $W_{\text{nouveau}} = H(z, c)$
 - d. Créer nouvel îlot I_{nouveau} avec poids W_{nouveau}
3. Pour chaque îlot I_i inactif pendant K étapes consécutives :
 - a. Calculer norme de gradient moyenne g_i sur la fenêtre
 - b. Si $g_i < g_{\text{seuil}}$ ET $N_{\text{îlots}} > N_{\text{min}}$:
 - Lancer distillation vers îlots voisins pendant D étapes
 - Supprimer I_i